


E3. Arquitectura Objetivo en Azure y Fabric

Documento de decisiones — Área de Datos
Septiembre 2026 | Autor: Adrian Villalba

E3. Arquitectura Objetivo — Azure + Fabric



1. Ingesta sin afectar la operación

SQL Server (citas por IPS): Data Pipeline de Fabric con Copy Data incremental por columna de marca de agua (fecha_modificación). Cada ejecución trae solo registros nuevos o modificados. Horario nocturno (2-5 AM). Se recomienda solicitar réplicas de lectura (Always On readable secondary) para cero impacto en producción.

MongoDB (WhatsApp): Data Pipeline con conector MongoDB, incremental por campo timestamp. Los eventos son append-only, lo que simplifica la ingesta. Mismo horario nocturno.

Idempotencia: Ambos pipelines usan MERGE INTO (upsert) al escribir en Bronze. Si se ejecutan dos veces con los mismos datos, no duplican registros.

2. Capas y modelo canónico multi-cliente

Patrón Medallion en un único Lakehouse de Fabric:

Bronze (crudo)

Datos tal cual llegan, en formato Parquet, particionados por client_id y fecha_carga. No se modifica ni limpia nada. Es respaldo y trazabilidad. Acceso restringido: solo el equipo de datos de dondoctor.

Silver (limpio y canónico)

Cada IPS llega con esquemas diferentes (columnas, códigos de estado, formatos de fecha). Se resuelve con un archivo de mapping por cliente

(YAML) que define la traducción al esquema canónico de 21 columnas (el mismo implementado en el pipeline E4). Cuando se onboardea una IPS nueva, solo se crea su mapping sin tocar el código del pipeline. En esta capa se aplican reglas de calidad (deduplicación, edades anómalas, anomalías temporales) y se elimina PII: cédula y teléfono se eliminan, solo se conserva paciente_id (hash).

Gold (consumo)

Modelo estrella: fact_citas (una fila por cita, métricas precalculadas), dim_paciente, dim_especialidad, dim_ips, dim_tiempo, y scoring_ausentismo (predicciones del modelo E5). Todos los clientes comparten las mismas tablas con client_id. La seguridad se garantiza con RLS.

3. Seguridad y privacidad

Aislamiento por cliente (Row-Level Security)

- Power BI: RLS configurado sobre client_id. Cada usuario de IPS solo ve sus filas.
- Lakehouse Gold: vistas con filtro por client_id, asignadas por workspace role.
- Bronze y Silver: acceso restringido al equipo de datos. Ningún cliente accede.

Datos sensibles (Ley 1581/2012)

Capa	Cédula/teléfono	Nombre	paciente_id
Bronze	Sí (tal cual llega)	Sí	Sí
Silver	ELIMINADOS	ELIMINADO	Sí (hash)
Gold	No existen	No existe	Sí (hash)

Bronze retiene datos originales como respaldo legal, con acceso restringido. Desde Silver, los pacientes son identificables solo por paciente_id (hash irreversible). Si una IPS necesita vincular un score con un paciente real, lo hace en su propio sistema.

4. Capacidad, costo y aislamiento de cargas

Supuestos

Variable	Valor	Justificación
IPS clientes	50 (año 1)	Piloto con 3, escalamiento gradual
Citas por IPS/mes	20.000	Promedio del piloto + clientes grandes
Filas nuevas/mes	1.000.000	50 × 20K
Eventos WhatsApp/mes	2.000.000	~2 por cita (envío + entrega)
Almacenamiento Gold	~2 GB (año 1)	Parquet comprimido
Retención Bronze	24 meses	Requisito legal

Costo estimado

Componente	SKU	Costo mensual (USD)
Fabric capacity	F2 (2 CU)	\$262
Almacenamiento OneLake	~50 GB total	Incluido en F2
Power BI Pro (5 usuarios)	Pro	\$50
Total estimado		~\$312/mes

F2 es suficiente para 50 IPS con batch diario. Si escala a 200+ IPS, se sube a F4 (\$525/mes).

Aislamiento ETL vs. dashboards

- Pipelines de ingesta corren entre 2:00 y 5:00 AM. Si no terminan a las 6:30, se pausan y alertan.
- Horario laboral (7 AM - 7 PM): capacidad reservada para Power BI y SQL analytics endpoint.
- Fabric prioriza workloads por tipo (Interactive > Pipeline). ETL nunca bloquea el tablero de gerencia.

5. Ambientes: desarrollo, pruebas y producción

Ambiente	Workspace	Datos	Uso
Dev	ws-datos-dev	Subset (3 IPS, 3 meses)	Desarrollo de pipelines
Test	ws-datos-test	Copia anonimizada de prod	Validación, pruebas de regresión
Prod	ws-datos-prod	Datos reales	Operación diaria

- Promoción Dev → Test → Prod con Deployment Pipelines de Fabric (un clic). Solo promueve artefactos, nunca datos.
- Git integration: notebooks y pipelines versionados en el mismo repositorio. Cambios pasan por pull request.
- Regla: nunca se desarrolla directamente en producción.

6. Consumo por modelos e IA de forma trazable

Acceso: Fabric expone un SQL analytics endpoint sobre el Lakehouse Gold. Los modelos conectan por SQL estándar (ODBC/JDBC), sin copiar datos fuera de Fabric. Notebooks de ML dentro de Fabric acceden directamente vía Spark.

Trazabilidad: Cada ejecución del modelo escribe a scoring_ausentismo en Gold:

Campo	Contenido
cita_id	Cita evaluada
client_id	IPS del paciente
probabilidad	Score del modelo (0.0 a 1.0)
modelo_versión	Ej: lr_b_v1.2
features_hash	Hash del conjunto de features usado
fecha_scoring	Timestamp de cuándo se generó

Microsoft Purview (incluido en Fabric) proporciona linaje automático: desde Bronze hasta Power BI. Los modelos de IA solo leen de Gold, nunca de Bronze o Silver.

7. Qué NO haría en Fabric

Decisión	Razón
NO streaming en tiempo real	Batch diario cubre el caso. Streaming cuesta 3-5x más sin beneficio. Evaluar en fase
NO entrenamiento pesado de ML	Reentrenamiento trimestral con notebooks Spark es suficiente. Azure ML solo si escala a deep learning.
NO como base transaccional	Fabric es analítico (OLAP). El sistema de citas sigue en SQL Server. Fabric consume, no reemplaza.
NO un lakehouse por cliente	Con 50+ IPS sería inmanejable. Un solo lakehouse con client_id + RLS es más simple y barato.
NO Data Activator	Requiere streaming, que no implementamos en fase 1. Se evaluaría junto con streaming en fase 2.