

Prueba Tecnica

Lider e Ingeniero de Datos

DonDoctor

Adrian Villalba
Septiembre 2026

Contenido: E1 Diagnostico | E2 Estrategia | E3 Arquitectura
E6 Resumen Ejecutivo | Registro de Tiempo

E1. Diagnostico y Calidad de Datos

Se analizaron 4 fuentes de datos: citas de 3 IPS (Norte, Sur, Occidente) en CSV y eventos de WhatsApp en JSONL. El analisis completo esta en notebooks/E1_diagnostico_calidad.py en el repositorio.

Volumetria

Fuente	Filas	Columnas	Formato
IPS Norte	6,555	11	CSV (coma)
IPS Sur	5,312	20	CSV (coma)
IPS Occidente	4,228	12	CSV (punto y coma)
WhatsApp	38,941	5	JSONL

9 hallazgos de calidad

ID	Hallazgo	Volumen	Severidad	Tratamiento
H1	Esquemas heterogeneos entre IPS	4,228	ALTO	Homologacion en unificar_datos.py
H2	Datos personales en Sur (cedula,	5,312	CRITICO	Eliminados en unificar_datos.py
H3	Edades anomalas (-1 y 999)	274	MEDIO	Reemplazados por nulo
H4	Duplicados cita_id en Norte	198	ALTO	Deduplicados por fecha reciente
H5	Estado REAGENDADA no documentado	903 (5.6%)	ALTO	Decision de negocio (E2)
H6	Citas futuras con estado ATENDIDA	67	MEDIO	Flag anomalia temporal
H7	Refs rotas en WhatsApp	12,069 (31%)	ALTO	Se filtran al cruzar
H8	Flag recordatorio inconsistente	402	MEDIO	Se usa WhatsApp como fuente
H9	Fecha creacion > fecha cita	121	BAJO	Flag fecha posterior

Reglas de calidad implementadas

22 tests automatizados en tests/test_calidad.py (pytest), organizados en 9 reglas (R1-R9). Validan: unicidad de cita_id, completitud de campos criticos, rangos de edad, consistencia de estados, integridad referencial con WhatsApp, y coherencia temporal.

Preguntas al dueno del dato (priorizadas)

- H5: Que significa exactamente REAGENDADA? La cita original se cierra o se modifica?
- H7: Por que el 31% de eventos WhatsApp no tiene referencia a cita? Es un bug del sistema?
- H2: IPS Sur incluye cedula y telefono. Existe autorizacion de los pacientes?
- H1: Hay un esquema canonico oficial o cada IPS define el suyo?
- H6: Las 67 citas futuras con estado ATENDIDA son errores del sistema o correcciones manuales?
- H4: Los 198 duplicados en Norte son reintentos del sistema o registros genuinos?
- H9: Las 121 citas con fecha_creacion > fecha_cita son reagendamientos o errores?
- H8: El campo recordatorio_enviado se mantiene actualizado o se puede deprecar?

E2. Estrategia y Producto de Datos

Documento completo de 4 paginas disponible en docs/E2_estrategia_producto_datos.pdf

0. Tratamiento de datos realizado

Pipeline de 3 capas (raw -> clean -> consumo) que homologa esquemas de las 3 IPS, elimina datos personales, corrige 9 hallazgos de calidad y genera un modelo dimensional (fact_citas + dimensiones) listo para analisis.

1. Definicion unificada de ausentismo

Ausentismo = $\text{NO_ASISTIO} / (\text{ATENDIDA} + \text{NO_ASISTIO}) = 15.8\%$. Norte 14.8%, Sur 17.8%, Occidente 14.8%. La discrepancia con Comercial (12-14%) es por incluir cancelaciones en el denominador. Se excluyen REAGENDADA (897 citas, 5.7%) y CANCELADA. Gobernanza: definicion unica documentada, calculo centralizado en capa de consumo, revision trimestral.

2. Posicion sobre servicios de Comercial

Benchmark entre IPS: Lanzar con rediseño. Comparar solo IPS de perfil similar. Sin revelar identidad. Riesgo legal bajo, riesgo etico medio. Diseño mes 2, lanzamiento mes 3.

Informe a EPS con pacientes: No lanzar. Compartir scores individuales a terceros requiere autorizacion expresa (Ley 1581/2012). Los factores de riesgo correlacionan con vulnerabilidad socioeconomica. Alternativa: informe agregado sin identificar individuos.

3. Producto de datos prioritario

Tablero operacional de gestion de ausentismo con actualizacion diaria. El recordatorio WhatsApp reduce ausentismo en 9 pp (de 20.2% a 11.2%). Hoy solo el 49% de las citas lo reciben. IPS Sur tiene mayor margen de mejora (10.2 pp). Meta: cobertura al 90%, reduccion ≥ 2 pp a 90 dias, adopcion $\geq 80\%$ semanal.

4. Sobre tiempo real

No implementar ahora. Batch diario es suficiente: el ausentismo se gestiona con horas o dias de anticipacion. Streaming cuesta 3-5x mas sin beneficio. Evaluar en fase 2.

5. Impacto economico

\$115 millones COP en agenda desperdiciada al ano en 3 IPS (1,922 inasistencias x \$60,000). ~\$27 millones recuperables llevando cobertura WhatsApp del 49% al 90%, sin costo adicional.


6. Hoja de ruta - 90 dias

- Mes 1: Data warehouse en Fabric, pipeline batch, definicion aprobada, prototipo tablero.
- Mes 2: Tablero en produccion, alertas de cobertura, benchmark v1, modelo predictivo v1.
- Mes 3: Onboarding 2 IPS adicionales, benchmark lanzado, revision de resultados.

E3. Arquitectura Objetivo en Azure y Fabric

Documento completo de 3 paginas disponible en docs/E3_arquitectura_azure_fabric.pdf

E3. Arquitectura Objetivo — Azure + Fabric



1. Ingesta sin afectar la operacion

Data Pipeline de Fabric con Copy Data incremental (watermark) en horario nocturno (2-5 AM). SQL Server via replicas de lectura; MongoDB via conector incremental por timestamp. Idempotente: MERGE INTO (upsert) evita duplicados.

2. Capas y modelo canonico multi-cliente

- Bronze: datos crudos en Parquet, particionados por client_id y fecha_carga. Solo equipo datos.
- Silver: esquema canonico 21 columnas. Mapping YAML por cliente para homologar. PII eliminada.
- Gold: fact_citas + dimensiones + scoring_ausentismo. Todos los clientes con client_id + RLS.

3. Seguridad y privacidad

RLS por client_id en Power BI y Gold. PII eliminada desde Silver (Ley 1581/2012). Bronze con acceso restringido (solo equipo datos). Purview para linaje automatico.

4. Capacidad y costo

Supuestos: 50 IPS, 1M filas/mes, ~2 GB en Gold. Fabric F2 (\$262/mes) + Power BI Pro (\$50) = \$312/mes. Pipelines 2-5 AM; capacidad reservada para dashboards en horario laboral.

5. Ambientes

Deployment Pipelines: Dev -> Test -> Prod. Git integration para notebooks y pipelines. Nunca se desarrolla en produccion.

6. Consumo por IA trazable

SQL analytics endpoint sobre Gold. Tabla scoring_ausentismo con: cita_id, probabilidad, modelo_version, features_hash, fecha_scoring. Modelos solo leen de Gold, nunca de Bronze/Silver.

7. Que NO en Fabric

- NO streaming (batch diario cubre el caso, streaming cuesta 3-5x mas).
- NO entrenamiento pesado de ML (notebooks Spark suficientes; Azure ML si escala).
- NO como base transaccional (Fabric es OLAP; citas siguen en SQL Server).
- NO un lakehouse por cliente (inmanejable a 50+ IPS; un solo lakehouse con RLS).

E6. Resumen Ejecutivo para Gerencia General

1. Cual es el ausentismo real?

15.8%, calculado sobre las 12,166 citas que debian ocurrir (atendidas + no asistio) durante el ultimo ano en las tres IPS piloto.

La diferencia con el 12-14% de Comercial no es un error: Comercial incluye cancelaciones en el denominador, lo que diluye la tasa. Un paciente que cancela libera la agenda; uno que no llega la desperdicia. El indicador correcto es 15.8%.

Esto representa \$115 millones COP en agenda desperdiciada al ano en solo 3 IPS.

2. En que IPS intervenir primero?

IPS Sur. Tiene el ausentismo mas alto (17.8% vs 14.8% en Norte y Occidente), la menor cobertura de WhatsApp (48.4%), y el mayor margen de mejora: 10.2 pp de reduccion con recordatorio.

Accion inmediata: llevar la cobertura de recordatorios del 49% al 90%, empezando por Sur. Costo adicional practicamente cero. Recuperacion estimada: ~\$27 millones COP/ano.

3. Se deben lanzar los servicios de Comercial?

Servicio	Recomendacion	Razon
Benchmark entre IPS	Si, con rediseño	Comparar solo IPS de perfil similar. Sin revelar identidad. Riesgo legal bajo.
Informe EPS con pacientes	No lanzar	Riesgo legal alto (Ley 1581/2012). Riesgo etico alto. Alternativa: informe agregado.

En resumen: el ausentismo es 15.8%, no 12-14%. Intervenir primero en Sur con WhatsApp. Lanzar benchmark con rediseño; no lanzar informe EPS. Priorizar el tablero operacional como primer producto de datos.

Registro de Tiempo

Tiempo total dedicado: ~8 horas.

Bloque	Tiempo	Actividades principales
E1 - Diagnostico	1.5 h	Perfilamiento de 4 fuentes, identificacion de 9 hallazgos, reglas de calidad, preguntas al dueño
E4 - Pipeline	2.0 h	3 scripts (unificar, limpiar, consumo), modelo dimensional, 22 tests
E2 - Estrategia	1.5 h	Documentación de 4 paginas, definicion de ausentismo, analisis de servicios, hoja de ruta
E5 - Modelo predictivo	1.5 h	Feature engineering, 2 escenarios, 4 modelos, analisis de fairness, 3 figuras
E3 - Arquitectura	1.0 h	Diagrama de arquitectura, documento de 3 paginas con 7 decisiones
E6 - Resumen y cierre	0.5 h	Resumen ejecutivo, USO-IA.md, README, PDF consolidado

El orden de trabajo fue: E1 -> E4 -> E2 -> E5 -> E3 -> E6. Se priorizo E4 despues de E1 para tener datos limpios antes de escribir la estrategia. E2 se hizo despues del pipeline para que las cifras del documento fueran verificables.